

# Sieci neuronowe – laboratorium nr 3

## Sprawozdanie

Oznaczenia:

$h$  – liczba neuronów w warstwie ukrytej

$b$  – rozmiar mini – batcha

$w$  – zakres wag początkowych (od  $-w_i^0$  do  $+w_i^0$ )

$\alpha$  – współczynnik uczenia


$m$  – współczynnik momentum

$d$  – współczynnik dropout

Poniższe testy prowadzone są do 100000 iteracji na danych treningowych

## Test 1. Wpływ autoenkodera

$$h = 200; b = 20; w = 0,2; \alpha_0 = 0,02; m_0 = 0,005$$

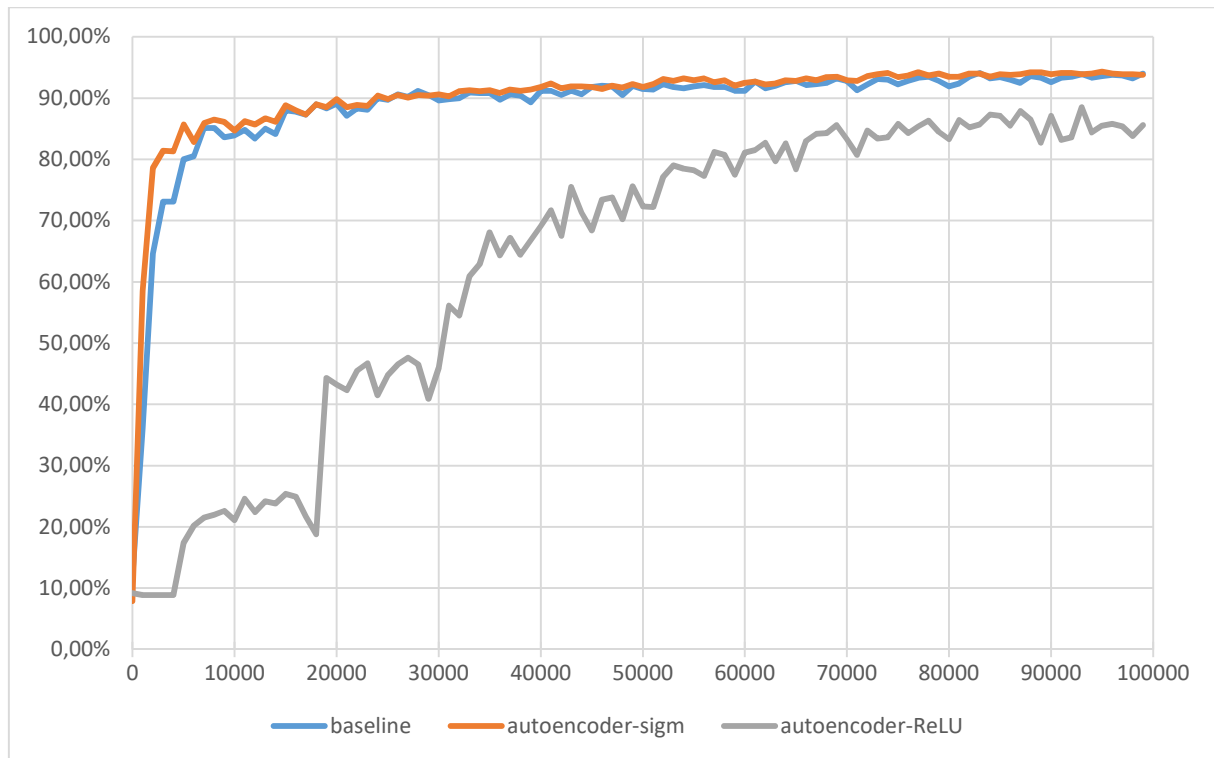


Budowa sieci	Dokładność	Czas	Dane treningowe
Bez enkodera	0,9454	473,809	100000
Enkoder	0,9496	570,901	106020
Enkoder z funkcją Softmax	0,9491	575,729	106020

Enkoder przyspiesza początkowe fazy uczenia

## Test 2. Funkcja aktywacji

$$h = 200; b = 20; w = 0,2; \alpha_0 = 0,02; m_0 = 0,005$$




Budowa sieci	Dokładność	Czas	Dane treningowe
Bez enkodera	0,9454	473,809	100000
Enkoder z Sigmoidą i Softmaxem	0,9496	570,901	106020
Enkoder z ReLU i Softmaxem	0,8909	517,246	102020

Funkcja ReLU się nie sprawdza

Sigmoida z Softmaxem jest minimalnie lepsza od podstawowego modelu

## Test 3. Dropout


 $h = 200; b = 20; w = 0,2; \alpha_0 = 0,02; m_0 = 0,005; d - \text{zmienny}$ 


$d$	Dokładność	Czas	Dane treningowe
0	0,9482	571,626	106020
0,05	0,9358	521,909	106020
0,1	0,9265	582,153	106020
0,2	0,9182	602,373	106020
0,5	0,8997	602,514	106020

Najlepszy wynik daje sieć bez dropoutu

## Test 4. Liczba neuronów w warstwie ukrytej

$h$  – zmienny;  $b = 20$ ;  $w = 0,2$ ;  $\alpha_0 = 0,02$ ;  $m_0 = 0,005$ ;  $d = 0$



$h$	Dokładność	Czas	Dane treningowe
10	0,101	63,243	106020
20	0,6245	96,407	106020
50	0,9132	151,516	106020
100	0,9339	276,273	106020
200	0,9488	625,574	106020

W podejściu bez autoenkodera 20 neuronów wystarczało do wyuczenia sieci, po zastosowaniu enkodera potrzeba 50.